




Estadística Descriptiva: La Anatomía de los Datos

El manual visual para describir, resumir y analizar
conjuntos de datos en Ciencia de Datos.

Variables

Numéricas (Cuantitativas)


Responden a: ¿Cuánto?



Continuas

Toman cualquier valor real, limitado solo por el instrumento de medición.

Ejemplos: Altura, tiempo, temperatura.



Discretas

Basadas en un conjunto de valores enteros distintos.

Ejemplos: Automóviles registrados, número de hijos.



Ordinales

Categorías con un orden lógico, sin diferencia numérica exacta entre ellas.

Ejemplos: Tallas de ropa, notas académicas.



Nominales

Valores sin secuencia lógica.

Ejemplos: Sexo, religión, marca.

Categóricas (Cualitativas)

Responden a: ¿Qué tipo?

Media (Promedio)



$$\bar{x} = \frac{1}{n} \sum x_i$$

```
media = np.mean(datos)
```


Mediana (El Centro Exacto)



Si la muestra es impar, es la posición central. Si es par, es el promedio de los dos centrales.


```
mediana = np.median(datos)
```

Moda (El Más Frecuente)



El valor que aparece con mayor frecuencia en la distribución.


```
moda = stats.mode(datos)
```



Asimetría a la Izquierda


Media Mediana Moda

$\text{Media} < \text{Mediana} < \text{Moda}$



Simetría

$\text{Media} = \text{Mediana} = \text{Moda}$



Asimetría a la Derecha

Moda Mediana Media

$\text{Moda} < \text{Mediana} < \text{Media}$

Regla de Oro: La Media siempre es arrastrada hacia la cola de la asimetría. La Mediana resiste y se mantiene en el centro de los datos.


Marcadores de Posición: Cuartiles y Percentiles

Dividen y analizan la distribución de los datos, informando cómo se distribuyen los valores en relación con los demás.



```
q1 = np.quantile(data, 0.25)  
p75 = np.percentile(data, 75)
```


Exploded View




```
plt.boxplot(data, vert=False)
```


El 50% exacto de tus datos vive dentro de la caja central.

Midiendo el Ruido: Rango y Rango Intercuartílico



```
rango = np.max(data) -  
np.min(data)  
ric = np.percentile(data, 75) -  
np.percentile(data, 25)
```





Varianza (σ^2)

El promedio de la diferencia elevada al cuadrado entre cada valor y la media. Los desvíos grandes cuentan más que proporcionalmente.


Desvío Estándar (s)

La raíz cuadrada de la varianza. Devuelve la métrica a las mismas unidades originales de los datos, haciéndola interpretable.

Varianza = Promedio de las distancias al cuadrado.


```
varianza = np.var(xs)
desvio = np.std(xs)
```

La Regla del 68-95-99.7: El mapa visual del desvío estándar.



- 68% de los datos caen a un desvío estándar de la media.
- 95% de los datos caen a dos desvíos estándar.
- 99.7% de los datos caen a tres desvíos estándar.

Comparando Peras con Manzanas: Coeficiente de Variación



$$CV = \frac{s_n}{\bar{x}} * 100$$

Concepto: El Coeficiente de Variación es el desvío estándar dividido por la media.


Insight: El CV es una métrica adimensional (no tiene unidades). Permite comparar la dispersión relativa de variables con medias o unidades completamente distintas.

Covarianza (Dirección de la Relación)

Mide la asociación lineal entre ambas variables.

Covarianza Positiva


X e Y tienden a moverse juntas



$$\text{cov}_{XY} = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$$

Covarianza Cercana a Cero


Las variables se mueven independientemente



```
# Matriz de varianzas y covarianzas  
np.cov(X)
```

Correlación (Fuerza y Dirección)

La correlación es la versión estandarizada de la covarianza.



Acotada estrictamente entre -1 y 1. A diferencia de la covarianza, la correlación no tiene unidades físicas.

```
np.corrcoef(X)
```

Matriz de Diagnóstico

Categoría	Covarianza	Correlación
Naturaleza	Asociación lineal en unidades originales.	Covarianza estandarizada.
Límites	De $-\infty$ a $+\infty$.	Estrictamente acotada de -1 a 1.
Unidades	Posee unidades físicas dependientes de las variables.	Adimensional (Sin unidades).
Uso Principal	Dirección de la relación geométrica.	Fuerza y dirección fácilmente interpretables.


Regla práctica: Siempre prefiere la correlación para interpretar y comunicar la fuerza de una relación.

Caso de Estudio: Análisis de Ventas 2004

¿Qué país tuvo mayor dispersión en sus ventas durante el año 2004?

Japan 2004


Media Global: 3553.88
Mediana: 3184.80




```
std_japan = np.std(sales_2004_japan)
iqr_japan = q75_japan - q25_japan
```

USA 2004

Media Global: 3553.88
Mediana: 3184.80



```
std_usa = np.std(sales_2004_usa)
iqr_usa = q75_usa - q25_usa
```



Hallazgo 1 (Dispersión)

El Rango Intercuartílico, el Desvío Estándar y el Coeficiente de Variación confirman que Japón presentó mayor dispersión en sus ventas que USA en 2004.

Hallazgo 2 (Simetría)

Como la Media (3553) es mayor que la Mediana (3184), diagnosticamos una asimetría a la derecha. Ventas excepcionalmente altas arrastran el promedio.

La estadística descriptiva no es solo resumir números; es construir el plano estructural que revela la verdadera historia detrás del ruido.