
✓ ***Asignatura: Ciencia de Datos***

Unidad 1: Teoría - Estadística Descriptiva

Universidad Nacional de Chilecito


Objetivos de la clase

- Repasar las medidas de tendencia central (media, mediana y moda)
- Repasar cómo la media, mediana y moda son afectadas por la asimetría
- Estudiar las medidas de correlación y covarianza.

✓ Estadística descriptiva y medidas de tendencia

La estadística descriptiva es una rama de la estadística que se enfoca en describir, resumir y analizar un conjunto de datos. Una de las herramientas más utilizadas en estadística descriptiva son las medidas de tendencia central, que son valores que representan el centro o la posición central de un conjunto de datos. Las tres medidas de tendencia central más comunes son la media, la mediana y la moda.

Tipos de variable



Hay diferentes maneras en que los diferentes tipos de variables se pueden describir de acuerdo con las formas en que se pueden estudiar, medir y presentar.

Variables numéricas

Las variables numéricas tienen valores que describen una cantidad medible como un número.

Responden a preguntas del tipo «**cuánto**» o «**cuántos**».

Por lo tanto las variables numéricas son **variables cuantitativas**.

Las variables numéricas se pueden describir con más detalle como **continuas** o **discretas**:

Una variable continua puede tomar cualquier valor entre un determinado conjunto de números reales.

El valor dado a una observación para una variable continua puede incluir valores tan pequeños como lo permita el instrumento de medición.

Ejemplos de variables continuas incluyen altura, tiempo, edad y temperatura.

En una **variable discreta** las observaciones pueden tomar un valor basado en un conjunto de valores enteros distintos.

Una variable discreta no puede tomar el valor de una fracción entre un valor y el siguiente valor más cercano.

Los **ejemplos de variables discretas** incluyen el número de automóviles registrados, el número de ubicaciones comerciales y el número de hijos en una familia, todos ellos medidos como unidades completas (es decir, 1, 2, 3 automóviles).

Los datos recopilados para una variable numérica son datos cuantitativos.

Variables categóricas

Las variables categóricas tienen valores que describen una «cualidad» o «característica» de una unidad de datos, como «qué tipo» o «qué categoría».

Las variables categóricas pertenecen a una categoría entre cierto número de categorías mutuamente **excluyentes** (en una categoría o en otra) y exhaustivas (incluyen todas las opciones posibles).

Por lo tanto, las variables categóricas son variables cualitativas y tienden a estar representadas por un valor no numérico.

Las variables categóricas pueden describirse como ordinales o nominales:

En una variable ordinal las observaciones pueden tomar valores que se puede ordenar o clasificar lógicamente.

Las categorías asociadas con las variables ordinales se pueden clasificar según un orden, pero no necesariamente hay una diferencia numérica entre cada categoría.

Ejemplos de variables categóricas ordinales:

las notas académicas (es decir, A, B, C), las tallas en la ropa (es decir, pequeño, mediano, grande, extra grande) y las actitudes (es decir, muy de acuerdo, de acuerdo, en desacuerdo, totalmente en desacuerdo). En una variable nominal las observaciones pueden tomar un valor que no se puede organizar en una secuencia lógica.

Ejemplos de variables categóricas nominales incluyen sexo, tipo de negocio, color de ojos, religión y marca.

Los datos recopilados para una variable categórica son datos cualitativos.

✓ Medidas de Tendencia Central

✓ Media

Dados los n números $\{x_1, x_2, \dots, x_n\}$ la media aritmética se define como:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + x_2 + \dots + x_n}{n}$$

Por ejemplo, para la muestra 8, 5 y -1, su media es:

$$\bar{x} = \frac{8 + 5 + (-1)}{3} = 4$$

```
import numpy as np

datos = [2, 3, 5, 7, 11]
media = np.mean(datos)

print("Media:", media)
```

```
Media: 5.6
```

✓ Mediana

La mediana es el valor del "medio" de una lista **ordenada** de datos (o el valor que separa la primera mitad y la segunda mitad de una distribución).

Para una lista ordenada la mediana es calculada de diferente manera dependiendo de la cantidad de elementos de la misma:

Impar:

[1, 2, 3, 5, **7**, 8, 9, 10, 15]

9 elementos

La mediana es el valor de la posición 5 (la posición del “medio”)

Mediana = 7

Par:

[-5, -1, 0, **1**, **2**, 3, 8, 20]

8 elementos

La mediana es la **media de los valores en las dos posiciones centrales**

Mediana = $(1+2)/2 = 1.5$

```
import numpy as np

datos = [-5, -1, 0, 1, 2, 3, 8, 20]
mediana = np.median(datos)

print("Mediana:", mediana)
```

Mediana: 1.5

✓ Moda

La moda es el **valor que aparece con mayor frecuencia** o más veces en la distribución.

Por ejemplo, la moda de [0,1,1,2,2,2,2,3,3,4,4,4,5] es 2.

La moda no es necesariamente única. Puede ocurrir que haya dos valores diferentes que sean los más frecuentes.

Por ejemplo, para [10, 13, 13, 20, 20], tanto 13 como 20 son la moda.

En Python, podemos calcular la moda utilizando la librería SciPy de la siguiente manera:

```
from scipy import stats


datos = [0,1,1,2,2,2,2,3,3,4,4,4,5]
```

```
moda = stats.mode(datos)

print("Moda:", moda.mode)
```

Moda: 2


✓ Asimetría



- Una distribución con asimetría a izquierda, significa que la cola de la izquierda es más larga que la de la derecha (gráfico de la izquierda).
- Una distribución simétrica no presenta este fenómeno dado que sus colas son de igual longitud (gráfico del centro).
- Una distribución con asimetría a derecha significa que la cola del lado derecho es más larga que la del lado izquierdo (gráfico de la derecha)

Asimetría y las medidas de Tendencia Central

La media, mediana y moda son afectadas por la asimetría



Asimetría a izquierda

Simetría

Asimetría a derecha

Media < Mediana < Moda Media = Mediana = Moda Moda < Mediana < Media

✓ Medidas de Posición

Cuartiles y percentiles son medidas estadísticas que se utilizan para dividir y analizar la distribución de un conjunto de datos. Estas medidas proporcionan información sobre cómo se distribuyen los valores en relación con los demás.

Cuartiles

Los cuartiles dividen un conjunto de datos en cuatro partes iguales, cada una conteniendo el 25% de los datos. Los cuartiles más comúnmente utilizados son:

- Primer cuartil (Q_1): También conocido como el cuartil inferior o el percentil 25 (P25), divide los datos de manera que el 25% de los valores sean menores o iguales a este valor.
- Segundo cuartil (Q_2): Es el valor que se encuentra en la mediana, es decir, el punto medio de la distribución. También se conoce como el percentil 50 (P50).
- Tercer cuartil (Q_3): También conocido como el cuartil superior o el percentil 75 (P75), divide los datos de manera que el 75% de los valores sean menores o iguales a este valor.

Los cuartiles son útiles para comprender la dispersión y la forma de la distribución de los datos.



Cuartiles con NumPy: Para obtener los cuartiles utilizando NumPy, puedes utilizar la función `numpy.quantile()`. Aquí tienes un ejemplo de cómo calcular los cuartiles:

```
import numpy as np

# Datos de ejemplo
data = np.array([30, 36, 47, 50, 52, 52, 56, 60, 63, 70, 70, 110])

# Calcular los cuartiles
q1 = np.quantile(data, 0.25)
q2 = np.quantile(data, 0.50)
```

```
q3 = np.quantile(data, 0.75)
```

```
# Imprimir los cuartiles  
print("Primer cuartil (Q1):", q1)  
print("Segundo cuartil (Q2):", q2)  
print("Tercer cuartil (Q3):", q3)
```

```
Primer cuartil (Q1): 49.25  
Segundo cuartil (Q2): 54.0  
Tercer cuartil (Q3): 64.75
```

```
np.median(data)
```


```
np.float64(54.0)
```

✓ Percentiles

Los percentiles son valores que dividen un conjunto de datos en cien partes iguales, proporcionando una medida más detallada de la distribución. Algunos percentiles comunes son:

- Percentil 25 (P25): Es equivalente al primer cuartil (Q1) y representa el valor por debajo del cual el 25% de los datos caen.
- Percentil 50 (P50): Es equivalente al segundo cuartil (Q2) y representa la mediana de los datos.
- Percentil 75 (P75): Es equivalente al tercer cuartil (Q3) y representa el valor por debajo del cual el 75% de los datos caen.
- Percentil 90 (P90): Representa el valor por debajo del cual el 90% de los datos caen.

Los percentiles proporcionan información más detallada sobre cómo se distribuyen los datos, especialmente en los extremos de la distribución.



Tanto los cuartiles como los percentiles son útiles para resumir y analizar grandes conjuntos de datos, y son ampliamente utilizados en campos como la estadística, la

investigación social, la economía y muchos otros. Estas medidas permiten comprender mejor la distribución, la dispersión y los valores atípicos de los datos.

Percentiles con NumPy

Para calcular los percentiles con NumPy también puedes utilizar las funciones `numpy.percentile()`. Solo necesitas especificar el valor del percentil deseado como argumento. Aquí tienes un ejemplo:

```
import numpy as np

# Datos de ejemplo
data = np.array([30,36,47,50,52,52,56,60,63,70,70,110])

# Calcular percentiles con NumPy
p25 = np.percentile(data, 25)
p50 = np.percentile(data, 50)
p75 = np.percentile(data, 75)


# Imprimir percentiles con NumPy
print("Percentil 25 (P25):", p25)
print("Percentil 50 (P50):", p50)
print("Percentil 75 (P75):", p75)
```

```
Percentil 25 (P25): 49.25
Percentil 50 (P50): 54.0
Percentil 75 (P75): 64.75
```

✓ Diagrama de Caja y su relación

```
import pandas as pd
import matplotlib.pyplot as plt

# Crear el diagrama de caja
plt.boxplot(data, vert=False)
plt.grid()
plt.show()
```



✓ Medidas de Dispersión o Variabilidad

Las medidas de variabilidad indican cómo están esparcidos los datos.

Vamos a presentar:

- Rango
- Varianza
- Desvío estándar
- Coeficiente de variación


Estas medidas proveen información complementaria a las medidas de tendencia central (media, mediana y moda).

✓ Rango y Rango Intercuartil

Sean $x_1, x_2, x_3, \dots, x_n$ los datos de una muestra ordenada en orden creciente, el rango es $x_n - x_1$

El rango intercuartil es la diferencia entre el tercer y el primer cuartil de la distribución.

Acumula el 50% de la distribución y, a diferencia del rango, es un estadístico robusto, es decir que se ve poco afectado por valores extremos.



Rango

```
import numpy as np

# Datos de ejemplo
data = np.array([30,36,47,50,52,52,56,60,63,70,70,110])

# Calcular el rango
rango = np.max(data) - np.min(data)

# Imprimir el rango
print("Rango:", rango)
```

Rango: 80

```
import pandas as pd

# Datos de ejemplo
data = pd.DataFrame({'A': [30,36,47,50,52,52,56,60,63,70,70,110]})

# Calcular el rango
rango = data['A'].max() - data['A'].min()

# Imprimir el rango
print("Rango:", rango)
```

Rango: 80

Rango Intercuartílico

La distancia entre Q₁ y Q₃ es una medida sencilla de dispersión que da el rango cubierto por la mitad de los datos.

Esta distancia se denomina rango intercuartil (IQR o RIC) y se define como:

$$\text{RIC} = Q_3 - Q_1$$

```
import numpy as np

# Datos de ejemplo
data = np.array([30,36,47,50,52,52,56,60,63,70,70,110])
```

```
# Calcular el rango intercuartílico con NumPy
q1 = np.percentile(data, 25)
q3 = np.percentile(data, 75)
ri = q3 - q1

# Imprimir el rango intercuartílico con NumPy
print("Rango intercuartílico (RI) con NumPy:", ri)
```

Rango intercuartílico (RI) con NumPy: 15.5

✓ Varianza

La varianza es un valor numérico utilizado para describir cuánto varían los números de una distribución respecto a su media.

Si tenemos un conjunto de valores de una variable, la varianza se calcula de la siguiente forma:

$$\sigma_n^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Siendo:

x_i : cada dato

$\bar{x}$: media de los datos

n : número de datos

Esto es el promedio de **la diferencia elevada al cuadrado entre cada valor y la media**

```
import numpy as np

xs = np.array([8, 5, -1])

np.var(xs)

np.float64(14.0)
```

✓ Desvío Estándar

Es la raíz cuadrada de la varianza

$$s_n = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

El desvío estándar es la raíz cuadrada de la varianza

El desvío es una medida de la dispersión de los datos

NO es la desviación promedio con respecto de la media. Como los desvíos están elevados al cuadrado los desvíos muy grandes cuentan más que proporcionalmente.

```
import numpy as np

xs = np.array([8, 5, -1])

np.std(xs)

np.float64(3.7416573867739413)
```


```
np.var(xs) == np.std(xs)**2

np.True_
```

✓ Varianza y desvío Estándar

Una ventaja del desvío estándar es que **está expresada en las mismas unidades** que se usaron para medir los datos.

(En cambio, la varianza tiene otras unidades ya que está elevada al cuadrado.)



Haz doble clic (o ingresa) para editar

Coeficiente de Variación

Es el desvío estándar dividido por la media

$$CV = \frac{s_n}{\bar{x}} \cdot 100$$

El coeficiente de variación permite **comparar la dispersión de variables diferentes**.

Sirve si las variables tienen medias distintas.

También si las variables están expresadas en unidades distintas.

El coeficiente de variación **no tiene unidades**.

✓ Medidas de asociación lineal entre variables


- Covarianza
- Correlación

Covarianza

Decimos que dos variables X e Y, tienen covarianza positiva cuando tienden a encontrarse por encima de su media al mismo tiempo y tienen covarianza negativa cuando al mismo tiempo, tienden a encontrarse una por debajo y otra por encima.

En cambio X e Y tienen **covarianza cercana a cero** cuando las variables pueden encontrarse por encima o por debajo de su media **independientemente** de lo que haga la otra.

La covarianza mide la asociación lineal entre ambas variables, es decir, qué tanto se asemeja la relación con una función lineal.



✓ Matriz de Covarianzas

La covarianza se mide como

$$cov_{XY} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Nota:

- Si hablamos de una muestra, se divide en $n-1$, si hablamos de población se divide en n

La covarianza de un conjunto de datos con p variables se puede representar con una matriz de $p \times p$ llamada **matriz de varianzas y covarianzas**:

- En la diagonal se encuentra la varianza de cada acción
- En el resto de la matriz se encuentran las covarianzas

1000*Covariances								
	^GSPC	^IXIC	XOM	C	GE	MSFT	K	GM
^GSPC	0.633	0.929	0.505	0.495	0.448	0.258	0.261	1.226
^IXIC	0.929	1.737	0.340	0.584	0.507	0.482	0.211	1.842
XOM	0.505	0.340	3.253	-0.421	-0.017	0.268	0.318	2.197
C	0.495	0.584	-0.421	1.923	0.688	0.176	0.277	-0.242
GE	0.448	0.507	-0.017	0.688	1.834	0.761	0.232	0.049
MSFT	0.258	0.482	0.268	0.176	0.761	1.945	0.181	1.315
K	0.261	0.211	0.318	0.277	0.232	0.181	1.045	0.688
GM	1.226	1.842	2.197	-0.242	0.049	1.315	0.688	9.429

```
import numpy as np

x = [-2.1, -1, 4.3]

y = [3, 1.1, 0.12]

X = [x, y]

print('X: ')
print(X)


print('-----')
print('Covarianzas: ')
np.cov(X)
```

```
X:
[[-2.1, -1, 4.3], [3, 1.1, 0.12]]
-----
Covarianzas:
array([[11.71      , -4.286      ],
       [-4.286      ,  2.14413333]])
```

La correlación es una **versión estandarizada** (dividida por los desvíos estándar) de la covarianza

$$r_{XY} = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})}{s_x} \frac{(y_i - \bar{y})}{s_y}$$

- La correlación está acotada entre 1 y -1.
- Siempre que la covarianza es positiva, la correlación es positiva y viceversa.
- La correlación no tiene unidades físicas, y la covarianza sí.



```
import numpy as np

x = [-2.1, -1, 4.3]
y = [3, 1.1, 0.12]

X = [x, y]

print('X: ')
print(X)

print('-----')
print('Correlación: ')
np.corrcoef(X)
```

```
X:
[[-2.1, -1, 4.3], [3, 1.1, 0.12]]
-----
Correlación:
array([[ 1.          , -0.85535781],
       [-0.85535781,  1.          ]])
```

✓ Práctica

La idea de esta práctica es ejercitar los puntos que vamos a necesitar para resolver el desafío.

Usaremos un resumen del dataset de Kaggle que tiene datos de ventas:

<https://www.kaggle.com/kyanyoga/sample-sales-data>

✓ Ejercicio 1

Leer los datos del archivo [/DataSet/sales_data_sample_exercise.csv](#)

Este archivo tiene algunos datos numéricos y otros de tipo cadena de caracteres.

Las columnas son:

- ORDERNUMBER: int, id de la orden
- SALES: float, monto abonado
- MONTH_ID: int, mes
- YEAR_ID: int, año
- PRODUCTLINE: str, producto
- COUNTRY: str, país de venta

¿Recuerdan que todos los elementos de una instancia de ndarray deben ser del mismo tipo? Entonces vamos a leer el archivo y crear una instancia de ndarray de tipo cadena de caracteres.

Con ayuda del siguiente código podrás vincular tu cuenta de Google Drive. Como recomendación te pedimos que crees una carpeta denominada como **AP_UNdeC** dentro de tu carpeta principal de Drive. Dentro de esa carpeta crea otra carpeta denominada **Data** en esa carpeta deberás subir siempre los archivos que necesites utilizar.

```
from google.colab import drive
drive.mount('/content/drive')
pathCurso = '/content/drive/MyDrive/CienciaDatos/DataSet/'
```

Con el siguiente comando podrás abrir el archivo que vamos a necesitar en ésta ocasión:

```
import numpy as np

# local:
data_location = pathCurso + 'sales_data_sample_excercise.csv'
data = np.genfromtxt(data_location, skip_header=1, delimiter='\t', dtype= st
data
```

```
sales = data[:, 1]
sales
```

```
sales_numeric = sales.astype(float)
sales_numeric
```

✓ Ejercicio 2

Calcular la media y mediana de la columna SALES. ¿Qué podemos decir sobre la simetría en la distribución de estos valores?

```
media = np.mean(sales_numeric)
media
```

```
np.float64(3553.889071909316)
```

```
mediana = np.median(sales_numeric)
mediana
```

```
np.float64(3184.8)
```

✓ Ejercicio 3

Usando esta función

```
import seaborn as sns

def distribution_plotter(data, label):
    sns.set(rc={"figure.figsize": (7, 5)})
    sns.set_style("white")
    dist = sns.histplot(data, stat = 'count', kde = False,
                        line_kws = {'linewidth':5},
                        binwidth = 500)
    dist.set_title('Distribucion ' + label + '\n', fontsize = 16)
```

Graficar los valores de la columna SALES para USA y Japan por separado para el año 2004.

¿Qué podemos decir sobre la distribución de ventas en esos dos países durante ese año?

```
data_anno = data[:, 3]
data_anno
```

```
data_pais = data[:, 5]
data_pais
```

```
mask_2004 = data_anno == '2004'
mask_japan = data_pais == 'Japan'
mask_usa = data_pais == 'USA'

mask_2004_japan = np.logical_and(mask_2004, mask_japan)
mask_2004_usa = np.logical_and(mask_2004, mask_usa)

sales_2004_japan = sales[mask_2004_japan]
sales_2004_japan_numeric = sales_2004_japan.astype(np.float)

sales_2004_usa = sales[mask_2004_usa]
sales_2004_usa_numeric = sales_2004_usa.astype(np.float)
```

```
distribution_plotter(sales_2004_japan_numeric, 'Japan 2004')
```

```
np.mean(sales_2004_japan_numeric)
```

```
np.median(sales_2004_japan_numeric)
```

```
distribution_plotter(sales_2004_usa_numeric, 'USA 2004')
```

```
np.mean(sales_2004_usa_numeric)
```

```
np.median(sales_2004_usa_numeric)
```

✓ Ejercicio 4

Podemos usar el desvío estándar o la distancia intercuartil para comprarar la dispersión en las ventas de USA y Japan durante el 2004

```
std_usa = np.std(sales_2004_usa_numeric)
```

```
q75_usa, q25_usa = np.percentile(sales_2004_usa_numeric, [75 ,25])  
iqr_usa = q75_usa - q25_usa  
iqr_usa
```

```
std_japan = np.std(sales_2004_japan_numeric)  
mean_japan = np.mean(sales_2004_japan_numeric)  
mean_japan, std_japan
```

```
q75_japan, q25_japan = np.percentile(sales_2004_japan_numeric, [75 ,25])  
iqr_japan = q75_japan - q25_japan  
iqr_japan
```

```
cv_usa = std_usa / mean_usa  
cv_usa
```

```
cv_japan = std_japan / mean_japan  
cv_japan
```

Las tres medidas calculadas indican que la dispersión en los valores de ventas para Japan es mayor que para USA en el 2004.

- La distancia intercuartil para Japan es mayor que para USA en el 2004, mostrando una mayor dispersión en los precios de venta.
- Lo mismo sucede con el desvío estándar.

El coeficiente de variación para el 2004 es mayor para Japan que para USA.